Protokol k profileru

IVS 2. projekt – CodePainCodeGain

Průběh měření:

Pro měření jsme vytvořily 3 separátní skripty pro porovnání výstupu profileru u různých optimalizacích. Profilování bylo provedeno v pythonu pomocí modulu cProfile výstup byl seřazen dle interního času vykonávání funkcí.

Kód a skripty:

Názvy skriptů a jejich význam:

- *standard_deviation.py:* Obsahuje prvotní a nejvíce intuitivní implementaci
- np_standard_deviation.py: Optimalizace čtení inputu a použití některých funkcí z knihovny numpy
- *check_std_correctness.py:* Načtení hodnot do stdin pomocí numpy, samostatný výpočet směrodatné odchylky funkcí stdev z modulu statistics.
- generate_nums.py: náhodné generování čísel pro výpočet směrodatné odchylky

Výstupy z profileru:

Ukázka je pro velikost vstupu o 10 000 000 číslech

```
python3 ../standard_deviation.py < test4-10to7.txt</pre>
                     profiling_stats
       40045586 function calls in 11.263 seconds
  Ordered by: internal time
         0.710 0.000 0.710 0.000 calculatormathlib.py:75(pow2)
                0.103 0.103 0.103 {method 'strip' of 'str' objects}
          0.103
          0.097
                 0.000
                                0.000 {built-in method _codecs.utf_8_decode}
                        0.105 0.000 codecs.py:319(decode)
                0.000 0.000 0.000 {built-in method builtins.print}
                0.000 6.125 6.125 standard_deviation.py:40(standard_deviation)
          0.000
          0.000
                 0.000 11.263 11.263 {built-in method builtins.exec}
          0.000
          0.000
                         0.000
                  0.000
                                11.263 <string>:1(<module>)
          0.000
                  0.000
          0.000
                  0.000
                         0.000
                                 0.000 {method 'disable' of '_lsprof.Profiler' objects}
```

```
python3 ../np_standard_deviation.py < test4-10to7.txt</pre>
                        profiling_stats
        20000025 function calls in 8.494 seconds
  Ordered by: internal time
  ncalls tottime percall cumtime percall filename:lineno(function)
np_standard_deviation.py:20(sum_of_squared_differences)
10000000
                    0.000
                                      0.000 calculatormathlib.py:75(pow2)
                           0.927
                    0.000
                                      3.146 np_standard_deviation.py:9(read_stdin)
            0.086
                   0.086
            0.009
                    0.009
                                      8.493 np_standard_deviation.py:40(main)
                    0.007
            0.007
                             0.007
            0.001
                    0.001
                                      8.494 <string>:1(<module>)
                                      8.494 {built-in method builtins.exec}
            0.000
                    0.000
                                      5.338 np_standard_deviation.py:28(standard_deviation)
            0.000
            0.000
                   0.000
                            0.000
                                      0.000 {built-in method builtins.print}
                   0.000
            0.000
                   0.000
                            0.007
                    0.000
                            0.007
            0.000
            0.000
                    0.000
                             0.000
                                      0.000 calculatormathlib.py:60(div)
            0.000
                    0.000
                             0.000
                                      0.000 calculatormathlib.py:102(sqrt)
                             0.000
                                      0.000 {built-in method builtins.isinstance}
            0.000
                    0.000
            0.000
                    0.000
                             0.000
            0.000
                   0.000
                             0.000
                                      0.000 calculatormathlib.py:36(sub)
            0.000
                   0.000
                             0.000
                                      0.000 fromnumeric.py:2172(_sum_dispatcher)
            0.000
                    0.000
                             0.000
                                      0.000 {built-in method builtins.len}
                    0.000
                             0.000
            0.000
            0.000
                    0.000
                             0.000
                                      0.000 {method 'items' of 'dict' objects}
```

```
python3 check_std_correctness.py < test4-10to7.txt</pre>
577367520.9077069
                            profiling_stats
   Ordered by: internal time
                                           5.056 check_std_correctness.py:13(read_stdin)
                                         0.000 {method 'get' of 'dict' objects}
0.640 {method 'split' of 'str' objects}
0.000 {method 'append' of 'list' objects}
                                 0.640
              0.640
                       0.640
                       0.000
                                           0.102 {method 'strip' of 'str' objects}
                                0.096
                                            0.000 {built-in method codecs.utf 8 decode}
             0.096 0.000
              0.008
              0.000
                       0.000
                                  0.000
                        0.000
                                  0.000
              0.000
                                            0.000 {built-in method math.gcd}
                                            0.000 {built-in method builtins.sum}
              0.000
                        0.000
                                  0.001
                                            0.000 fractions.pv:356(forward)
              0.000
                        0.000
                                 0.000
```

```
0.000 {built-in method builtins.print}
               0.000
                        0.000
      0.000
      0.000
               0.000
                        0.000
                                 0.000 statistics.py:198(<genexpr>)
               0.000
                        0.000
      0.000
                                 0.000 statistics.py:721(<genexpr>)
      0.000
                        0.000
               0.000
      0.000
               0.000
                       16.500
                                16.500 statistics.py:725(variance)
                                 0.000 {built-in method builtins.isinstance}
      0.000
               0.000
                        0.000
      0.000
               0.000
      0.000
               0.000
                       0.000
                                 0.000 fractions.py:256(numerator)
      0.000
               0.000
                       0.000
                                 0.000 fractions.py:260(denominator)
2/1
               0.000
                        0.000
      0.000
               0.000
      0.000
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
                                 0.000 __init__.py:579(__missing__)
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
      0.000
               0.000
      0.000
               0.000
                       0.000
                                0.000 __init__.py:565(__init__)
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
      0.000
               0.000
                       0.000
                                 0.000 {built-in method builtins.iter}
               0.000
                       21.735 21.735 <string>:1(<module>)
      0.000
               0.000
               0.000
                        0.000
      0.000
                                 0.000 __init__.py:640(update)
0.000 {method 'items' of 'dict' objects}
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
                                 0.000 {built-in method math.sqrt}
      0.000
               0.000
      0.000
               0.000
                        0.000
      0.000
               0.000
                        0.000
                                 0.000 fractions.py:193(as_integer_ratio)
```

```
python3 check_std_correctness.py < test4-10to7.txt</pre>
577367520.9077069
                          profiling_stats
  Ordered by: internal time
                    0.000
                  0.000
                                     2.167 {built-in method numpy.array}
                           0.656
                                     3.171 check_std_correctness.py:13(read_stdin)
                                     0.188 {method 'read' of '_io.TextIOWrapper' objects}
            0.086
                    0.086
            0.008
                    0.001
                            19.740 19.740 <string>:1(<module>)
           0.001
                   0.000
                            0.000 0.000 fractions.py:62(__new__)
           0.000
           0.000
                   0.000
                            0.000
            0.000
            0.000
                    0.000
                             0.001
                    0.000
                             0.000
            0.000
                                      0.000 fractions.py:356(forward)
            0.000
                    0.000
                             0.000
                                      0.000 {built-in method builtins.print}
            0.000
                    0.000
            0.000
                    0.000
                             0.000
                                     0.000 statistics.py:198(<genexpr>)
            0.000
                    0.000
                           16.560 16.560 statistics.pv:725(variance)
```

```
0.000
              0.000
                      0.000
      0.000
              0.000
      0.000
              0.000
                      0.000
                              0.000 statistics.py:721(<genexpr>)
     0.000
              0.000
                      0.000
              0.000
                      0.000
                               0.000 {built-in method builtins.isinstance}
     0.000
     0.000
              0.000
                      0.000
     0.000
     0.000
              0.000
                     0.000
                              0.000 statistics.py:264(_convert)
     0.000
              0.000 16.560 16.560 statistics.py:816(stdev)
     0.000
              0.000
     0.000
              0.000
                      0.000
                               0.000 __init__.py:579(__missing_
                     0.000
     0.000
              0.000
     0.000
              0.000
                     0.000
     0.000
2/1
              0.000
      0.000
              0.000
                      0.000
                               0.000 {built-in method builtins.len}
      0.000
                      0.000
              0.000
      0.000
              0.000
              0.000
                      0.000
                               0.000 __init__.py:640(update)
      0.000
      0.000
              0.000
                      0.000
              0.000
                      0.000
```

Výsledky:

Považujeme skript *check_std_correctness.py* za přesný výsledek kvůli použití standardizované funkce na výpočet. Tato skutečnost bude zobrazena na grafu zobrazující chybu v přesnosti původního programu.

Kód v check_std_correctness.py byl dále optimalizován pomocí numpy.arr() funkce a vylepšenému čtení stdin.

Testy byly provedeny o velikostech: 10 10³ 10⁶ 10⁷ 10⁸ číslic


Odchylka:

Výpočet odchylky

$$\delta = \left| \frac{original - control}{original} \right| \cdot 100$$

	Sample size
test1	10
test2	1000
test3	1000000
test4	10000000
test5	100000000

	test1	test2	test3	test4	test5
original decimal	0.6970111	0.806305	0.7060071	0.9076962	0.700383
control decimal	0.6970111	0.8063052	0.7060004	0.9077069	0.700451
δ	0.00%	0.00%	0.09%	0.12%	0.97%




Výsledky profileru:

	ORIGINAL						
	test1	test2	test3	test4	te st5		
time (s)	0	0.002	1.13	11.263	111.798		
function calls	60	4024	4004576	40045586	400455692		
values	563285339.697011	576589468.806305	577408887.706007	577367520.907696	577373407.700383		

	NUMPY OPTIMIZED						
	test1	test2	test3	test4	test5		
time (s)	0.001	0.001	0.874	8.494	85.871		
function calls	45	2025	2000025	20000025	200000025		
values	563285339.697011	576589468.806305	577408887.706007	577367520.907696	577373407.700383		

CONTROL - STATISTICS STDEV						
		test1	te st2	test3	test4	test5
time (s)			0.003	2.116	20.993	
function calls	239		6400	6005572	60046703	
values	5	63285339.6970110	576589468.8063050	577408887.7060000	577367520.9077060	

	CONTROL - STATISTICS STDEV (readstdin optimized)						
	test1	test2	test3	test4	test5		
time (s)		0.002	1.972	19.74	195.118		
function calls	228	5395	5001015	50001136	500001323		
values	563285339.697011	576589468.806305	577408887.706000	577367520.907706	577373407.700451		



Zjištění a návrh optimalizace:

Náš původní program označovaný *original*, či soubor *standard_deviation.py* nejvíce trpí na neefektivní čtení vstupu ze stdin. To zároveň značí zdvojnásobený počet funkčních volání.

Další dílčí ztráta času nastává při výpočtu sumy a volání funkce *sum_of_squared_differences*.

Použití *numpy.arr* nám pomohlo se zbavit extra for loopu, čímž se výrazně změnčil počet funkčních volání a čas výpočtu.

Za korektní výstup považujeme tabulky označené *CONTROL*, kde voláme funkci *stdev* z vestavěné knihovny *statistics*. Tímto dále určujeme odchylku při různých velikostí vstupů. Komplexnější struktura volání této funkce nám prodlužuje čas výpočtu, ale zároveň dosahuje vyšší přesnosti.

Optimalizace:

Některé optimalizace jsme již zmínili a máme k nim zároveň i data, tak tyto budeme již považovat za probrané.

Použití nativních operací jako +-*/ namísto volání externích funkcí.

Maticové operace pomocí Numpy arrays.

Paralelní zpracování např. u funkce *sum_of_squared_differences* by nám rapidně urychlilo výpočet. Použití *python multiprocessing* knihovny.

GPU akcelerace by byla také velmi užitečná pro práci s velkými vstupy. Dosažení tohoto by bylo možné pomocí např. *CuPy* knihovna, která má operace akcelerované pomocí *CUDA* technologie od Nvidie.

Original (standard_deviation.py):

```
from pstats import SortKey
import sys
def read_stdin():
    for line in sys.stdin:
      for num in nums:
            res = Math.add(res, powRes)
      return res
      read_stdin()
     __name__ = "__main__":
cProfile.run('main()', "profiling_stats")
p = pstats.Stats("profiling_stats")
p.strip_dirs().sort_stats('time').print_stats()
```

Numpy Optimized (np_standard_deviation.py):

```
float_vals = np.array(input_data.split(), dtype=np.float64)
Math = CalculatorMathLib()
        powRes = Math.pow2(num - barNum)
def standard_deviation(nums):
    sumOfNums = np.sum(nums)
argsLen = len(nums)
    S = Math.sqrt(Math.div(sum_of_squared_differences(nums, barX), Math.sub(argsLen, 1)))
def main():
    nums = read stdin()
    S = standard_deviation(nums)
    cProfile.run('main()', "profiling_stats")
p = pstats.Stats("profiling_stats")
    p.strip_dirs().sort_stats('time').print_stats()
```

Control - STATISTICS STDEV (readstdin optimized) [check_std_correctness.py]:

```
import sys
import statistics
import numpy as np
import cProfile
import pstats
from pstats import SortKey
def compute_std(arr):
    S = statistics.stdev(arr)
    return S
def read stdin():
    input_data = sys.stdin.read()
    float_vals = np.array(input_data.split(), dtype=np.float64)
    return float_vals
def main():
    nums = read stdin()
    print(compute_std(nums))
if __name__ = "__main__":
    cProfile.run('main()', "profiling_stats")
    p = pstats.Stats("profiling_stats")
    p.strip dirs().sort stats('time').print stats()
```

Generátor čísel (generate_nums.py):

```
import random
import sys

def generate_floats(num_floats, lower_bound, upper_bound):
    return [random.uniform(lower_bound, upper_bound) for _ in range(num_floats)]

# Number of floats to generate
num_floats = 1_000
# Interval bounds
lower_bound = -1_000_000_000
upper_bound = 1_000_000_000

if __name__ = "__main__":
    if len(sys.argv) > 1:
        num_floats = int(sys.argv[1])
    floats = generate_floats(num_floats, lower_bound, upper_bound)
# Num of decimals_places = 7
    decimals_places = 10
    rounded_floats = [round(fl, decimals_places) for fl in floats]
    print(" ".join(map(str, rounded_floats)))
```